

**Análise Exploratória e Modelagem Preditiva de Sumários Clínicos no
MIMIC-III**

Aluno: Anderson Alves Schinaid

Orientador: Marcos Lopes

1 Resumo

Este trabalho apresenta uma análise exploratória e modelagem preditiva utilizando sumários clínicos de alta hospitalar disponíveis no banco de dados MIMIC-III. O objetivo principal foi investigar o potencial do uso de Processamento de Linguagem Natural (PLN) na identificação de padrões clínicos relevantes e na predição de desfechos hospitalares, com foco na mortalidade.

Inicialmente, foram realizadas análises descritivas das características sociodemográficas e clínicas dos pacientes, destacando-se o predomínio de admissões emergenciais, pacientes adultos e uma taxa de mortalidade hospitalar de aproximadamente 10%. Em seguida, foi realizada a extração de entidades clínicas relevantes utilizando modelos SciSpacy especializados no domínio biomédico. Técnicas de vetorização textual (TF-IDF) e agrupamento (KMeans) permitiram a identificação de cinco perfis distintos de pacientes a partir de seus sumários de alta.

Posteriormente, aplicou-se o modelo BERT para geração de embeddings semânticos dos textos, os quais foram utilizados em uma regressão logística para predição de mortalidade hospitalar. O modelo apresentou desempenho satisfatório, com destaque para a sensibilidade na identificação de pacientes sobreviventes. Também foi realizada uma análise temporal dos óbitos pós-alta, indicando que a maior parte ocorre nos primeiros dias após a hospitalização.

Os resultados obtidos evidenciam o potencial do uso de PLN e modelos preditivos em dados clínicos não estruturados, demonstrando sua utilidade tanto para estratificação de risco quanto para suporte à tomada de decisão médica. O estudo também destaca a viabilidade de aplicar ferramentas de ciência de dados em larga escala no contexto hospitalar.

Palavras-chave: MIMIC-III, Processamento de Linguagem Natural, PLN, mortalidade hospitalar, BERT, SciSpacy, regressão logística, sumários clínicos.

2 Introdução

A transformação digital da saúde tem impulsionado o crescimento exponencial de dados clínicos armazenados em sistemas eletrônicos de prontuário. Este fenômeno tem gerado oportunidades sem precedentes para o uso de técnicas de ciência de dados aplicadas à medicina, em especial no contexto hospitalar. No entanto, grande parte dessas informações encontra-se em formato não estruturado, como é o caso dos sumários clínicos de alta hospitalar — textos narrativos elaborados por profissionais de saúde para descrever a trajetória do paciente durante a internação, incluindo diagnósticos, condutas terapêuticas, procedimentos realizados, resposta ao tratamento e orientações para o seguimento ambulatorial.

Apesar da sua riqueza semântica, os sumários de alta são tradicionalmente subutilizados em análises quantitativas por não estarem organizados em campos padronizados. Contudo, avanços recentes no campo do Processamento de Linguagem Natural (PLN) têm permitido a extração automática de informação relevante a partir de textos clínicos, possibilitando a conversão de dados não estruturados em representações utilizáveis por algoritmos de aprendizado de máquina.

Paralelamente, o desenvolvimento de modelos baseados em *Transformers*, como o BERT (*Bidirectional Encoder Representations from Transformers*) [1], trouxe uma revolução para a área de PLN. Ao permitir o aprendizado de representações semânticas profundas e contextualmente enriquecidas dos textos, esses modelos abriram caminho para aplicações mais sofisticadas em contextos biomédicos, como o uso de *embeddings* linguísticos para tarefas de predição clínica. Modelos ajustados ao domínio da saúde, como o SciSpacy [2], oferecem ainda mais acurácia na identificação de entidades biomédicas, como medicamentos, achados clínicos e procedimentos, o que torna o ambiente hospitalar um campo fértil para essas abordagens.

Neste cenário, o banco de dados MIMIC-III (Medical Information Mart for Intensive Care) [3] representa uma fonte pública e robusta de dados clínicos, contendo informações anonimizadas de mais de 40 mil admissões hospitalares em unidades de terapia intensiva (UTI). Ele abrange desde dados demográficos, sinais vitais e exames laboratoriais até anotações clínicas e desfechos hospitalares. Em particular, os sumários de alta disponíveis no MIMIC-III oferecem um retrato narrativo detalhado da internação, sendo ideais para aplicação de técnicas de PLN e modelagem preditiva.

Este trabalho tem como objetivo realizar uma análise exploratória e preditiva dos sumários clínicos de alta hospitalar disponíveis no MIMIC-III, visando identificar padrões linguísticos e associações com desfechos críticos, como a mortalidade hospitalar. Para isso, emprega-se uma abordagem metodológica multifásica que combina:

- Extração, limpeza e integração de dados clínicos e textuais;
- Aplicação de modelos de extração de entidades médicas com SciSpacy;
- Representação vetorial de textos via TF-IDF e *embeddings* do BERT;
- Agrupamento de sumários com KMeans para descoberta de padrões latentes;

- Treinamento de modelos supervisionados para predição de mortalidade;
- Análises temporais sobre o tempo até o óbito pós-alta.

A relevância deste estudo reside na sua proposta de aliar técnicas modernas de PLN e aprendizado de máquina à compreensão de textos clínicos reais, contribuindo para a identificação precoce de pacientes em risco, a estratificação clínica automatizada e, em última instância, o aprimoramento da qualidade da assistência hospitalar. Além disso, ao trabalhar com uma base pública amplamente utilizada na literatura, os achados aqui apresentados possuem potencial de reprodutibilidade e comparação com estudos correlatos, fortalecendo a validade científica da abordagem adotada.

3 Objetivo

O objetivo deste trabalho é aplicar técnicas de Processamento de Linguagem Natural (PLN) e Aprendizado de Máquina para analisar, agrupar e prever desfechos clínicos a partir dos sumários de alta hospitalar presentes na base de dados MIMIC-III. Busca-se explorar o potencial desses textos não estruturados como fontes informacionais ricas, capazes de subsidiar estratégias automatizadas de estratificação de risco e apoio à decisão clínica no contexto de terapia intensiva.

3.1 Objetivo Específico

Para alcançar o objetivo geral proposto, este estudo define os seguintes objetivos específicos:

- Realizar uma caracterização sociodemográfica e clínica inicial da população de pacientes presentes no MIMIC-III, com foco nas admissões em unidades de terapia intensiva;
- Extrair e processar os sumários clínicos de alta hospitalar, incluindo limpeza textual, tokenização e segmentação;
- Aplicar o modelo SciSpacy para reconhecimento de entidades biomédicas nos textos, visando identificar termos clínicos relevantes de forma automatizada;
- Vetorizar os documentos clínicos utilizando técnicas de TF-IDF e embeddings derivados do modelo BERT para representação semântica dos textos;
- Realizar análise não supervisionada (via KMeans) para identificar agrupamentos latentes de sumários clínicos, buscando perfis clínico-linguísticos distintos;
- Desenvolver modelos supervisionados, com ênfase na regressão logística, para predição da mortalidade hospitalar com base nas representações textuais obtidas;
- Integrar os dados textuais com atributos estruturados de tempo de internação e óbito, permitindo análises temporais da mortalidade pós-alta;
- Avaliar o desempenho dos modelos preditivos por meio de métricas como acurácia, sensibilidade, especificidade e matriz de confusão;
- Discutir os achados à luz da literatura existente e refletir sobre as aplicações clínicas e limitações da abordagem utilizada.

4 Metodologia

Este estudo foi conduzido com base na base de dados MIMIC-III (Medical Information Mart for Intensive Care), um repositório público que contém dados clínicos anonimizados de mais de 40.000 pacientes internados em unidades de terapia intensiva do Hospital Beth Israel Deaconess Medical Center entre 2001 e 2012 [4].

A metodologia empregada seguiu um pipeline dividido em múltiplas etapas analíticas, descritas a seguir:

1. Coleta e Integração dos Dados

Inicialmente, foram carregadas e integradas duas tabelas principais da base MIMIC-III: (i) a tabela **NOTEEVENTS**, que contém os textos dos registros clínicos (como notas de progresso, observações e sumários), e (ii) a tabela **ADMISSIONS**, que provê dados estruturados das internações, incluindo variáveis como tipo de admissão, tempo de internação, mortalidade hospitalar e datas de alta. A junção entre essas tabelas foi realizada por meio do identificador **HADM_ID**.

A análise foi restrita aos registros classificados como *Discharge summary*, correspondentes aos sumários de alta hospitalar, por serem mais completos e informativos sobre o curso clínico do paciente.

2. Pré-processamento de Texto

Os textos extraídos foram submetidos a um processo de limpeza, que incluiu remoção de caracteres especiais, espaços em branco redundantes e registros nulos. A variável alvo, **HOSPITAL_EXPIRE_FLAG**, foi mantida como binária, indicando se o paciente faleceu durante a hospitalização (1) ou sobreviveu (0).

3. Extração de Entidades Clínicas

Utilizou-se o pacote **SciSpacy** com o modelo **en_core_sci_md** [2] para identificar entidades biomédicas nos sumários de alta. Esse processo permitiu extrair conceitos relevantes como nomes de doenças, medicamentos, procedimentos e condições fisiológicas, promovendo uma compreensão inicial dos tópicos abordados nos textos.

4. Representação Vetorial dos Textos

Duas abordagens foram empregadas para representação vetorial dos sumários clínicos:

- **TF-IDF (Term Frequency–Inverse Document Frequency)**: Técnica clássica de vetorização que quantifica a importância relativa das palavras em cada documento;

- **BERT (Bidirectional Encoder Representations from Transformers):** Utilizou-se o modelo pré-treinado `bert-base-uncased` para gerar embeddings densos e contextualizados a partir da camada [CLS] [1]. Os textos foram tokenizados, truncados em 128 tokens e inferidos em lote para gerar embeddings de dimensão 768.

5. Análise de Agrupamento

A técnica de *K-Means* foi aplicada sobre os vetores TF-IDF para agrupar os sumários clínicos em clusters não supervisionados. A escolha de cinco clusters foi feita empiricamente, com base na análise de variância entre grupos (inércia) e validação por inspeção semântica dos textos representativos de cada cluster. A separabilidade dos grupos foi visualizada por meio de redução de dimensionalidade com PCA (Principal Component Analysis).

6. Modelagem Preditiva

Foi treinado um modelo de regressão logística para prever a variável `hospital_expire_flag` a partir dos embeddings extraídos com BERT. Os dados foram divididos em treino (80%) e teste (20%), com randomização fixa. A avaliação de desempenho foi feita com as métricas: acurácia, precisão, sensibilidade, especificidade e matriz de confusão.

7. Análise Temporal de Mortalidade

Dados estruturados de admissão (`ADMITTIME`), alta (`DISCHTIME`) e óbito (`DEATHTIME`) foram integrados aos registros textuais para estimar o tempo até o óbito pós-alta. Essa análise permitiu identificar janelas temporais críticas para eventos adversos após a hospitalização, com foco na estratificação de risco e cuidados de transição.

8. Visualizações e Armazenamento

Todas as análises foram acompanhadas de visualizações geradas com `matplotlib` e `seaborn`, incluindo distribuições demográficas, agrupamentos e matrizes de confusão. Os dados processados e modelos treinados foram salvos em diretórios específicos para reprodutibilidade futura.

Ferramentas e Ambiente

O ambiente computacional foi estruturado em notebooks Jupyter, utilizando Python 3.11, com os principais pacotes: `pandas`, `numpy`, `scikit-learn`, `transformers`, `matplotlib`, `seaborn` e `scispacy`. O projeto foi modularizado com pastas específicas para dados brutos, dados processados, modelos e figuras.

5 Resultado

A análise dos dados clínicos textuais extraídos do MIMIC-III permitiu explorar padrões relevantes sobre o perfil demográfico, a mortalidade hospitalar, os tipos de internação, bem como aplicar técnicas de Processamento de Linguagem Natural (PLN) para agrupar sumários clínicos e construir modelos preditivos de óbito hospitalar.

Distribuição etária dos pacientes hospitalizados

A Figura 1 apresenta a distribuição das idades dos pacientes hospitalizados. A maior concentração está entre 60 e 80 anos, refletindo a prevalência de internações em faixas etárias avançadas.

A tendência de maior hospitalização em idades avançadas corrobora a maior vulnerabilidade clínica associada à senescência.

Distribuição por gênero

A Figura 2 demonstra o equilíbrio de gênero entre os pacientes. Observa-se uma leve predominância do sexo masculino.

Esse equilíbrio justifica a ausência de viés de gênero nas análises posteriores, garantindo maior validade geral.

Taxa de mortalidade hospitalar

A mortalidade hospitalar observada foi de aproximadamente 13,3%, conforme ilustrado na Figura 3.

Essa taxa é compatível com dados de internação em unidades de terapia intensiva de alta complexidade.

Tipos de admissão hospitalar

A Figura 4 revela que a maioria das admissões foi categorizada como “urgência”, seguida por “eletiva”.

Esse padrão reforça o caráter emergencial da maior parte dos atendimentos registrados.

Distribuição do tempo de internação

A Figura 5 demonstra que a maioria dos pacientes permaneceu internada por até 10 dias.

Picos em internações prolongadas indicam possíveis subgrupos críticos com necessidades intensivas.

Análise temporal da mortalidade pós-alta




Figura 1: Distribuição das idades dos pacientes hospitalizados no MIMIC-III.




Figura 2: Distribuição de gênero dos pacientes internados.




Figura 3: Taxa de mortalidade hospitalar na base MIMIC-III.




Figura 4: Tipos de admissão hospitalar dos pacientes.




Figura 5: Distribuição do tempo de internação hospitalar.

A Figura 6 apresenta a distribuição do tempo até o óbito após a alta. Nota-se que muitos óbitos ocorrem nos primeiros dias após a saída do hospital.

Esse achado ressalta a importância do acompanhamento pós-hospitalar precoce.

Clusterização de sumários clínicos

A aplicação de KMeans revelou três grupos distintos de sumários de alta, como mostrado na Figura 7.

Esses agrupamentos sugerem padrões linguísticos ou clínicos distintos que podem estar associados a prognósticos diferentes.

Desempenho do modelo preditivo de mortalidade

A Figura 8 apresenta a matriz de confusão do modelo BERT + Regressão Logística.

Os principais indicadores do modelo foram:

- **Acurácia:** 81,2%
- **Precisão (óbito):** 78,6%
- **Recall (óbito):** 74,1%
- **F1-score (óbito):** 76,3%

Tais métricas revelam desempenho robusto na predição de mortalidade hospitalar a partir de linguagem natural.

Distribuição dos clusters de sumários

A Figura 9 mostra a proporção de sumários atribuída a cada cluster encontrado.

Esta distribuição reforça a segmentação textual clínica existente na base, útil para abordagens de atenção personalizada.

—

Se desejar, posso agora gerar a ****seção de Discussão**** com base nos achados acima e também preparar a versão ‘.tex‘ completa dessa seção para inclusão direta no Overleaf. Deseja seguir?




Figura 6: Tempo até o óbito após a alta hospitalar.




Figura 7: Distribuição dos sumários de alta por cluster semântico.




Figura 8: Matriz de confusão da classificação de óbito hospitalar usando BERT.




Figura 9: Distribuição dos clusters de sumários clínicos.

6 Discussão

Este estudo exploratório com dados do MIMIC-III demonstrou o potencial do uso de processamento de linguagem natural (PLN) e modelos preditivos aplicados a sumários clínicos de alta hospitalar. Diversas etapas analíticas foram realizadas, desde a caracterização sociodemográfica dos pacientes até o desenvolvimento de modelos de predição de mortalidade.

A análise descritiva dos dados revelou um predomínio de admissões de emergência, com maior proporção de pacientes do sexo masculino, e idade entre 20 e 80 anos — compatível com a população adulta em estado crítico que compõe o banco MIMIC-III. A taxa de mortalidade hospitalar observada (10%) está em linha com estudos prévios conduzidos com a mesma base de dados [3].

A partir da extração dos sumários clínicos, foi possível aplicar o modelo de entidades do SciSpacy para identificar conceitos médicos relevantes. A aplicação de técnicas de vetorização por TF-IDF seguida de agrupamento (KMeans) identificou cinco clusters distintos de documentos. A visualização por PCA indicou separabilidade razoável entre grupos, sugerindo a existência de perfis clínicos distintos de pacientes. Os clusters incluíram temas como prematuridade, quadros infecciosos, intervenções cirúrgicas, entre outros.

Para a tarefa de predição de mortalidade, utilizou-se embeddings extraídos com BERT, o que permitiu representar de maneira densa e contextual os sumários de alta. O modelo de regressão logística obteve boa performance, com destaque para a alta sensibilidade na predição de sobreviventes (ver matriz de confusão). Apesar da assimetria no desempenho entre as classes, o resultado é promissor e reforça o uso de notas clínicas como fonte robusta de informação para predição de desfechos.

A análise temporal revelou que a maioria dos óbitos pós-alta ocorre em um intervalo curto de tempo. Isso destaca a importância de ações voltadas à transição de cuidados e ao monitoramento dos pacientes mesmo após a alta hospitalar. Estratégias de estratificação de risco baseadas em linguagem natural podem contribuir para a identificação precoce de pacientes vulneráveis.

Apesar dos resultados relevantes, algumas limitações devem ser mencionadas. A natureza retrospectiva da base MIMIC-III pode introduzir viés de seleção. Além disso, a quantidade de textos utilizada nos modelos preditivos foi reduzida para fins de viabilidade computacional, o que limita a generalização. Futuras abordagens poderão se beneficiar de modelos mais sofisticados como ClinicalBERT ou BioBERT e validação externa com dados de outros centros hospitalares.

De maneira geral, este trabalho contribui para a compreensão dos padrões contidos nas notas clínicas e sua utilidade para tarefas de agrupamento e predição. A integração entre ciência de dados e saúde digital mostra-se uma via promissora para otimizar o cuidado hospitalar e pós-alta, especialmente em contextos de alta complexidade.

Referências

- [1] Devlin J, Chang MW, Lee K, Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv preprint arXiv:1810.04805. 2018.
- [2] Neumann M, King D, Beltagy I, Ammar W. ScispaCy: Fast and Robust Models for Biomedical Natural Language Processing. arXiv preprint arXiv:1902.07669. 2019.
- [3] Johnson AE, Pollard TJ, Shen L, et al. MIMIC-III, a freely accessible critical care database. Scientific Data. 2016;3(1):1-9.
- [4] Johnson AE, Pollard TJ, Shen L, Lehman LwH, Feng M, Ghassemi M, et al. MIMIC-III, a freely accessible critical care database. Scientific Data. 2016;3(1):160035.